Hurtownie danych – Projekt – Etap 00

PWr. WIiT, Data: 10.04.2026

Student	----------	Ocena
Indeks	280556	
Imię	Mateusz	
Nazwisko	Tereba	

Proszę przygotować propozycję mini projektu Hurtowni Danych, zgodnie z poniższym zakresem, na najbliższe zajęcia (10.04. - konsultacje). Prezentacja proponowanego tematu, którą należy przygotować w PowerPoint (ok. 5 min.), odbędzie się na kolejnych zajęciach lab. 17.04.2026 r.

Propozycja dziedziny i tematu projektu

1. Tytuł projektu -propozycja

Analiza sprzedaży czekolady w latach 2023-2024

2. Ogólna charakterystyka dziedziny problemowej

Dziedzina obejmuje handel detaliczny wyrobami z czekolady, w różnych rodzajach sklepów. Charakteryzuje się ona dużą dynamiką sprzedaży oraz sezonowością, a także silnym powiązaniem z lojalnością klienta oraz działaniami promocyjnymi. Dane obejmują profil klienta, szczegóły sprzedaży oraz informacje o produkcie.

3. Cel przedsięwzięcia + propozycja pytań badawczych

Optymalizacja strategii sprzedaży, identyfikacja najbardziej dochodowych grup klientów i rodzajów produktów, a także analiza strategii przecen.

Pytania badawcze:

- Jak zawartość czekolady w produkcie wpływa na sprzedaż w poszczególnych krajach?
- Sprzedaż do jakich grup wiekowych generuje największy przychód?
- Czy przynależność do programu lojalnościowego wpływa pozytywnie na przychód ze sprzedaży?
- W jaki sposób wysokość przeceny wpływa na sprzedaż w zależności od marki.

4. Dane źródłowe (Podstawowe + uzupełniające) – zbiór danych co najmniej 100 000 rekordów!

Lokalizacja, dostępność danych źródłowych

https://www.kaggle.com/datasets/ssssws/chocolate-sales-dataset-2023-2024?resource=download

Tabela 1. Dostępne źródła danych.

Lp.	Plik, bazy danych	Typ	Liczba rek.	Rozmiar [MB]	Opis zawartości pliku
1	Sales.csv	CSV	1000000	~69	Zawiera dane opisujące wszystkie zawarte transakcje
2	Stores.csv	CSV	100	~0,004	Zawiera informacje o sklepach i ich lokalizacji
3	Calendar.csv	CSV	731	~0,02	Zawiera informacje o dniach sprzedaży
4	Customers.csv	CSV	50000	~1,35	Zawiera informacje o klientach sklepów
5	Products.csv	CSV	200	~0,01	Zawiera dane o produktach z czekolady

5. Problemy w rozpatrywanej dziedzinie

P01 - Trudność w określeniu progu rentowności udzielanych rabatów.
P02 - Nierównomierna opłacalność działalności sklepów w zależności od ich typu i lokalizacji.
P03 - Brak wiedzy o tym, jakie produkty przyciągają nowych członków programu lojalnościowego.
P04 – Trudność ustalenia najbardziej dochodowej strategii sprzedaży.

6. Zakres analizy – pytania badawcze

Q01 – Jaki jest próg rentowności dla udzielanych rabatów w zależności od marki i kategorii produktu?
Q02 – Jakie są różnice w przychodach i rentowności w zależności od typu sklepu oraz jego lokalizacji.
Q03 – Które kategorie produktów charakteryzują się najwyższą sprzedażą wśród nowych członków programu lojalnościowego?
Q04 – W jaki sposób zawartość kakao i wiek klienta determinują wielkość sprzedaży w poszczególnych krajach?

7. Propozycja analitycznego modelu danych

7.1. Fakty podlegające analizie oraz ich miary

Analizie będzie podlegał zbiór zarejestrowanych zdarzeń (tab. 2.)

Tabela 2. Fakty podlegające analizie

Lp.	Fakty	Miary	Uwagi
1.	Sale	Quantity, unit_price, discount, revenue, cost,	

7.2. Kontekst analizy faktów

Ustalony kontekst analizy faktów został przedstawiony w tab. 3.

Tabela 3. Wymiary analizy faktów

Lp.	Wymiar	Atrybuty	Uwagi
	Product	product_name, brand, category, cocoa_percent, weight_g	
	Date	Date, year, month, day, week, day_of_week	
	Customer	age, gender, loyalty_member, join_date	
	Store	store_name, city, country, store_type	

8. Wstępna ocena jakości danych źródłowych (na kolejnych zajęciach)

Tabela 2. Jakość źródeł danych.

Lp.	Plik, bazy danych	Uwagi dotyczące jakości danych
1	Sales.csv	Dane dobrej jakości, brak wartości null, natomiast wartości numeryczne mają kropki zamiast przecinków przez co nie da się ich zaimportować jako liczby.
2	Stores.csv	Dane dobrych jakości, brak wartości null.
3	Calendar.csv	Dane dobrych jakości, brak wartości null.
4	Customers.csv	Dane dobrych jakości, brak wartości null.
5	Products.csv	Dane dobrych jakości, brak wartości null.

Wnioski z realizacji zadania

- Temat wybrałem ponieważ znalazłem odpowiedni zbiór danych, o dobrej jakości, a także ponieważ osobiście uważam go za ciekawy oraz przystępny do zrozumienia. Zbiór danych jest również dobrze oceniany przez użytkowników na stronie Kaggle co również uważam za plus.