Hurtownie danych – Projekt – Etap 01

PWr. Wydział Informatyki i Telekomunikacji Data: 24.04.2026

Student	----------	Ocena
Indeks	280556	
Imię	Mateusz	
Nazwisko	Tereba	

1. Tytuł projektu

Analiza wzorców mobilności miejskiej i obciążenia infrastruktury na podstawie systemu Capital Bikeshare w Waszyngtonie.

2. Charakterystyka dziedziny problemowej

Dziedzina projektu obejmuje transport miejski oraz dynamicznie rozwijający się sektor mikromobilności, ze szczególnym uwzględnieniem systemów publicznego współdzielenia rowerów. Rozwiązania te stanowią kluczowy element infrastruktury komunikacyjnej w nowoczesnych aglomeracjach, odpowiadając na wyzwania związane z redukcją zatorów drogowych oraz zrównoważonym rozwojem.

Istotne dla tej dziedziny są również panujące warunki atmosferyczne, od których w dużym stopniu zależy zmienność w wykorzystaniu systemów rowerów miejskich. Pogoda wpływa nie tylko na samą decyzję o wypożyczeniu, ale także na zachowania użytkowników, takie jak długość przejazdów czy wybór docelowego miejsca zwrotu pojazdu.

Przedmiotem analizy będzie przejazd rowerem, to jest wypożyczenie i zwrócenie go. Zdarzenie to charakteryzuje się godziną i miejscem rozpoczęcia i zakończenia przejazdu, klasyfikacją wypożyczającego, typem wypożyczanego roweru, a także warunkami atmosferycznymi panującymi podczas przejazdu.

2.1 Opis obszaru analizy (wybrany fragment dziedziny, przeznaczony do szczegółowej analizy i opracowania hurtowni danych)

Analizowane dane ograniczają się do przejazdów ze stolicy Stanów Zjednoczonych miasta Waszyngton od maja 2020 do sierpnia 2024. Zbiór ten zawiera dane o każdym zarejestrowanym przejeździe, takie jak czas rozpoczęcia i zakończenia, stacje początkową i końcową, klasyfikacje wypożyczającego oraz typ pojazdu. Zbiór danych został dodatkowo rozszerzony o dane pogodowe z tego samego okresu, aby dodać odpowiedni kontekst do analizy.

2.2 Problemy w rozpatrywanej dziedzinie

- P01 – Nierównomierne obciążenie stacji – w godzinach szczytu niektóre stacje są wykorzystywane o wiele częściej niż inne, co może prowadzić do braku wolnych miejsc lub rowerów.
- P02 – Silna sezonowość – liczba przejazdów dynamicznie zmienia się w przeciągu roku co stanowi problem przy rozmieszczaniu zasobów.
- P03 – Różne zachowania użytkowników – osoby posiadające subskrypcje i sporadyczni użytkownicy posiadają inne wzorce korzystania z usług, co utrudnia przewidywanie zachowań użytkowników.
- P04 – Wpływ warunków atmosferycznych – zmienne warunki pogodowe zaburzają wzorce wypożyczeń i utrudniają przewidywanie zapotrzebowania.
- P05 – Preferencja wypożyczanych rowerów - wpływ dostępnych rodzajów rowerów na zachowania użytkowników.

2.3 Cel przedsięwzięcia

2.3.1 Oczekiwania i potrzeby w zakresie wsparcia podejmowania decyzji

- Jakie decyzje ma wspierać?

1. Wybór optymalnych lokalizacji dla nowych stacji w mieście
2. Alokacje odpowiedniej ilości rowerów na dane stacje
3. Wyznaczanie okresów serwisowania rowerów
4. Wybór rodzaju i kupno nowych rowerów
5. Rozbudowa obecnie istniejących stacji

2.3.2 Zakres analizy – badane aspekty – pytania badawcze

1. Q01 –Które ze stacji są najczęściej używane, a które najrzadziej?
2. Q02 – Jakie podróże są najczęściej wykonywane (pomiędzy którymi stacjami)?
3. Q03 – Czy istnieją miejsca, w których należy utworzyć nowe stacje?
4. Q04 – W jaki sposób warunki pogodowe wpływają na liczbę wypożyczeń rowerów?
5. Q05 – Czy subskrybenci wypożyczają rowery częściej od okazjonalnych użytkowników?
6. Q06 – W jakich okresach rowery są używane najmniej?
7. Q07 – Czy istnieje różnica w czasach przejazdów lub w pokonywanych dystansach pomiędzy rodzajami rowerów?

2.3.3 Potencjalni użytkownicy (**Interesariusze i użytkownicy**)

- Kto jest odbiorcą raportów i analiz?

  1. Zarząd spółki
  2. Dział ds. Operacji i Logistyki
  3. Dział Utrzymania Serwisu
  4. Dział Marketingu
  5. Władze Miasta
  6. Urbaniści

3. Dane źródłowe

3.1. Źródła danych

Charakterystyka pliku zawierający danę źródłowe przeznaczone do stworzenia tematycznej hurtowni danych jest przedstawiona w tab. 1.

Tabela 1. Zbiory danych źródłowych

Lp.	Plik	Typ	Liczba rek.	Rozmiar[MB]	Opis
1.	Daily_rent_detail	Csv	16086672	2795	Dane szczegółowo opisujące pojedyncze przejazdy
2.	Station_list	Csv	916	0.03	Zbiór stacji (id stacji, nazwa)
3.	Usage_frequency	Csv	873318	36.6	Dane przedstawiające zagregowane użycie poszczególnych stacji w danych dniach
4.	open-meteo-38.91N77.07W12m	Csv	38016	1.7	Dane przedstawiające warunki pogodowe w danych dniach co godzinę

3.2. Lokalizacja, dostępność danych źródłowych

Użyte do analizy dane zostały pobrane z platformy Kaggle oraz dodatkowo zbiór danych pogodowych ze strony Open-Meteo, który posiada większą dokładność (dane są zbierane co godzinę) niż zbiór z Kaggle (posiada on tylko dane dzienne).

- https://www.kaggle.com/datasets/taweilo/capital-bikeshare-dataset-202005202408
- https://open-meteo.com/en/docs/historical-weather-api

3.3. Słownik danych – interpretacja

Interpretacja oraz wyjaśnienie znaczeń pojęć dziedzinowych zostały zawarte w tab.2.

Tabela 2. Słownik atrybutów

Plik: daily_rent_detail.csv				
Lp.	**Atrybut**	**Typ danych**	**Znaczenie**	**Ograniczenia dziedzinowe, uwagi**
1.	end_lat	float	Szerokość geograficzna punktu końcowego.	Wartości zmiennoprzecinkowe z przedziału od 38 do 40. Mogą wystąpić wartości NULL, jeśli przejazd nie został poprawnie zakończony.
2.	end_lng	float	Długość geograficzna punktu końcowego.	Wartości zmiennoprzecinkowe z przedziału od -78 do -76. Mogą wystąpić wartości NULL, jeśli przejazd nie został poprawnie zakończony.
3.	end_station_id	integer	Identyfikator stacji końcowej.	Może być wartością NULL jeśli przejazd zakończył się poza stacją, w przeciwnym wypadku musi istnieć w tabeli station_list.
4.	end_station_name	string	Pełna nazwa stacji końcowej.	Może być wartością NULL jeśli przejazd zakończył się poza stacją, w przeciwnym wypadku musi istnieć w tabeli station_list.
5.	ended_at	datetime	Data i dokładny czas zakończenia przejazdu.	Data zapisana w formacie: YYYY-MM-DD HH:MM:SS. Wartość musi być późniejsza niż started_at oraz mieścić się w przedziale od maja 2020 do sierpnia 2024

6.	member_casual	string	Wskazuje typ użytkownika.	Wartość obligatoryjna, przyjmuje tylko dwie wartości dopuszczalne: member (zarejestrowany użytkownik) lub casual (okazjonalny).
7.	ridable_type	string	Rodzaj wypożyczonego roweru.	Wartość obligatoryjna, przyjmuje ograniczone wartości: docked_bike, electric_bike, classic_bike.
8.	ride_id	string	Unikalny identyfikator przejazdu.	16-znakowy ciąg alfanumeryczny. Obligatoryjny, unikalny dla każdego wypożyczenia (w danych źródłowych występują powtórzenia)
9.	start_lat	float	Szerokość geograficzna punktu startowego.	Wartość obligatoryjna zmiennoprzecinkowa z przedziału od 38 do 40.
10.	start_lng	float	Długość geograficzna punktu startowego.	Wartości obligatoryjne zmiennoprzecinkowe z przedziału od -78 do -76.
11.	start_station_id	integer	Identyfikator stacji początkowej.	Może być wartością NULL jeśli przejazd rozpoczął się poza stacją, w przeciwnym wypadku musi istnieć w tabeli station_list
12.	start_station_name	string	Pełna nazwa stacji początkowej.	Może być wartością NULL jeśli przejazd rozpoczął się poza stacją, w przeciwnym wypadku musi istnieć w tabeli station_list
13.	started_at	datetime	Data i dokładny czas rozpoczęcia przejazdu.	Data zapisana w formacie: YYYY-MM-DD HH:MM:SS. Wartość musi być wcześniejsza niż ended_at oraz mieścić się w przedziale od maja 2020 do sierpnia 2024

Plik: station_list.csv				
Lp.	**Atrybut**	**Typ danych**	**Znaczenie**	**Ograniczenia dziedzinowe, uwagi**
1.	station_id	integer	Unikalny identyfikator stacji dokującej.	Wartość obligatoryjna, unikalna, składa się z cyfr (w danych źródłowych występują powtórzenia)

2.	station_name	string	Pełna nazwa lokalizacji stacji.	Wartość obligatoryjna

Plik: usage_frequency.csv				
Lp.	**Atrybut**	**Typ danych**	**Znaczenie**	**Ograniczenia dziedzinowe, uwagi**
1.	date	date	Data, dla której podsumowano statystyki.	Data zapisana w formacie: YYYY-MM-DD. Wartość obligatoryjna, powinna mieścić się w przedziale od maja 2020 do sierpnia 2024
2.	dropoff_counts	int	Dzienna liczba zwrotów rowerów na danej stacji.	Wartość całkowita, nieujemna (w danych źródłowych zostały zapisane jako liczba zmiennoprzecinkowa)
3.	pickup_counts	int	Dzienna liczba wypożyczeń rowerów z danej stacji.	Wartość całkowita, nieujemna
4.	station_name	string	Pełna nazwa stacji rowerowej.	Wartość obligatoryjna, powinna znajdować się w tabeli station_list

Lp.	**Atrybut**	**Typ danych**	**Znaczenie**	**Ograniczenia dziedzinowe, uwagi**
1.	precipitation	float	Łączna liczba opadów z poprzedniej godziny w milimetrach.	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od 0 do 100. Nazwa atrybutu zmieniona względem oryginału.
2.	rain	float	Ilosć deszczu w przeciągu poprzedniej godziny w milimetrach	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od 0 do 100. Nazwa atrybutu zmieniona względem oryginału.
3.	snow_depth	float	Głebokość śniegu podana w metrach	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od 0 do 1.5. Nazwa atrybutu zmieniona względem oryginału.
4.	snowfall	float	Ilość śniegu w przeciągu poprzedniej godziny w centymetrach	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od 0 do 20. Nazwa atrybutu zmieniona względem oryginału.

5.	temperature	float	Temperatura powietrza na wysokości 2m nad ziemią podana w stopniach Celsjusza	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od -20 do 40 stopni Celsjusza. Nazwa atrybutu zmieniona względem oryginału.
6.	wind_speed	float	Średnia prędkość wiatru podana w km/h.	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od 0 do 200. Nazwa atrybutu zmieniona względem oryginału.
7.	time	datetime	Data i czas pomiaru.	Data zapisana w formacie: YYYY-MM-DD HH:MM:SS. Wartość obligatoryjna, unikalna. Musi mieścić się w przedziale od maja 2020 do sierpnia 2024

3.4. Ocena jakościowa danych

Wynik analizy jakościowej przeprowadzonej za pomocą programu Tableau oraz profilu danych SSIS został przedstawiony w tab. 3.

Tabela 3. Ocena jakościowa danych

Plik: daily_rent_detail.csv				
Lp.	**Atrybut**	**Typ danych**	**Zakres wartości**	**Uwagi - ocena jakości danych**
1.	end_lat	float	Wartości od 0 do 43,07	Występują wartości NULL (0.16%), wartości wychodzą poza odpuszczalny przedział.
2.	end_lng	float	Wartości od -78,1 do 0	Występują wartości NULL (0.16%), wartości wychodzą poza dopuszczalny przedział.
3.	end_station_id	integer	Wartości od 30200 do 33200, anomalia w postaci 2 wartości alfanumerycznych	Dwa wystąpienia wartości alfanumerycznej, reszta składa się z liczb zmiennoprzecinkowych (~89,9%) lub całkowitych (~0,4%) występują wartości NULL (~9,7%). Wartości alfanumeryczne nie występują w danych z pliku station_list.
4.	end_station_name	string	Długość od 10 do 61 znaków	Występują wartości NULL (9.7%)

5.	ended_at	datetime	Wartości od 01.01.2000 15:55:56 do 31.08.2024 23:59:55	Brak wartości NULL, daty poza dopuszczalnym zakresem
6.	member_casual	string	Wszystkie rekordy mają dokładnie 6 znaków	Brak wartości NULL, wszystkie wartości zgodne z ograniczeniami.
7.	ridable_type	string	Długość od 11 do 13 znaków	Brak wartości NULL, wszystkie wartości są poprawne.
8.	ride_id	string	Dokładnie 16 znaków	Brak wartości NULL, występują powtórzenia stanowią one 0.0009% zbioru.
9.	start_lat	float	Wartości od 38,37 do 39,14	Występują wartości NULL (10 rekordów), wartości mieszczą się w dopuszczalnym przedziale
10.	start_lng	float	Wartości od -77,4 do -76,78	Występują wartości NULL (10 rekordów), wartości mieszczą się w dopuszczalnym przedziale
11.	start_station_id	integer	Wartości od 30200 do 33200, anomalia w postaci 2 wartości alfanumerycznych	Dwa wystąpienia wartości alfanumerycznej, reszta składa się z liczb zmiennoprzecinkowych (~89,6%) lub całkowitych (~1,3%) występują wartości NULL (~9%). Wartości alfanumeryczne nie występują w danych z pliku station_list.
12.	start_station_name	string	Długość od 10 do 61 znaków	Występują wartości NULL (9%)
13.	started_at	datetime	Wartości od 01.05.2020 00:02:02 do 31.08.2024 23:57:12	Brak wartości NULL, wartości mieszczą się w dopuszczalnym przedziale

Plik: station_list.csv

Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych
1.	station_id	integer	Wartości od 30200 do 33200	Brak wartości NULL, natomiast występują powtórzenia wartości (procent unikalnych wartości wynosi 88.2%)
2.	station_name	string	Długości od 10 do 61 znaków	Brak wartości NULL, występuje 7 powtórzonych wartości (99.2% wartości jest unikalnych)

Plik: usage_frequency.csv				
Lp.	**Atrybut**	**Typ danych**	**Zakres wartości**	**Uwagi - ocena jakości danych**
1.	date	date	Wartości od 01.05.2020 do 31.08.2024	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym zakresie.
2.	dropoff_counts	int	Wartości od 0 do 460	Brak wartości NULL, liczby całkowite zapisane jako zmiennoprzecinkowe
3.	pickup_counts	int	Wartości od 1 do 444	Brak wartości NULL, wszystkie całkowitoliczbowe
4.	station_name	string	Wartości od 10 do 61	Brak wartości NULL

Plik: weather.csv				
Lp.	**Atrybut**	**Typ danych**	**Zakres wartości**	**Uwagi - ocena jakości danych**
1.	precipitation	float	Zakres wartości od 0 do 29	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.
2.	rain	float	Zakres wartości od 0 do 29	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.
3.	snow_depth	float	Zakres wartości od 0 do 0,16	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.
4.	snowfall	float	Zakres wartości od 0 do 3,15	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.
5.	temperature	float	Zakres wartości od -14,2 do 38,2	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.

6.	time	datetime	Zakres wartości od 01.05.2020 00:00:00 do 31.08.2024 23:00:00	Brak wartości NULL, wszystkie wartości unikalne, wartości mieszczą się w dozwolonym przedziale, format daty należy zmienić aby możliwe było wczytanie danych.
7.	wind_speed	float	Zakres wartości od 0 do 32,8	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.

Uwaga:
Ocena jakości atrybutu i jego wartości powinna umożliwić podjęcie decyzji, czy wymaga oczyszczenia zbioru wartości lub można pominąć ten atrybut w kontekście rozważanego zakresu analiz biznesowych.

4. Analityczne modele wielowymiarowe

4.1. Fakty **podlegające analizie oraz ich miary**

Analizie będzie podlegał zbiór zarejestrowanych zdarzeń (tab. 4.)

Tabela 4. Fakty podlegające analizie

Lp.	**Fakty**	**Miary**	**Uwagi**
1.	Rental	Duration, distance	Na podstawie tabeli wypożyczeń obliczono czas przejazdu i przebyty dystans (w linii prostej)

4.2. Kontekst analizy faktów

Ustalony kontekst analizy faktów został przedstawiony w tab. 5.

Tabela 5. Wymiary analizy faktów

Lp.	Wymiar	Atrybuty	Uwagi
1.	Date	Datetime, year, quarter, month, day_of_week, hour	Z danych z tabeli wypożyczeń wyodrębniono daty i godziny, pożyczenia i zwrotu roweru. W celu ułatwienia analizy w kontekście pory roku, miesiąca, dnia tygodnia i godziny.
2.	Location	latitude, longitude, name, is_station	Zagregowane dane z tabel wypożyczeń i stacji opisują miejsce oddania roweru, czy

			rower znajduje się na stacji i jeśli tak nazwę stacji.
3.	Weather	temperature, wind_speed, rain, snowfall, snow_depth	Z tabeli danych pogodowych wybrano wszystkie dane istotne dla analizy takie jak temperatura, wiatr, opady i głębokość śniegu.
4.	Client	member_casual	W kontekście klienta jedyną daną którą posiadamy jest status jego subskrypcji.
5.	Bike	ridable_type	W kontekście wypożyczanego roweru znamy tylko jego typ.

5. Wielowymiarowy Konceptualny Model (diagram klas UML)

Po zakończeniu analizy atrybutów źródła danych, ustaleniu faktu oraz jego kontekstu w postaci pięciu wymiarów. Zaproponowano konceptualny wielowymiarowy model analityczny na podstawie schematu gwiazdy (przedstawiony na rys. 1.). Składa się on z faktu Rental (wypożyczenie) oraz jego pięciu wymiarów: Date (data), Location (lokalizacja), Weather (pogoda), Client (klient) i Bike (rower).

Uwaga: własności klas nie zawierają kluczy obcych (jest to mechanizm implementacyjny!)

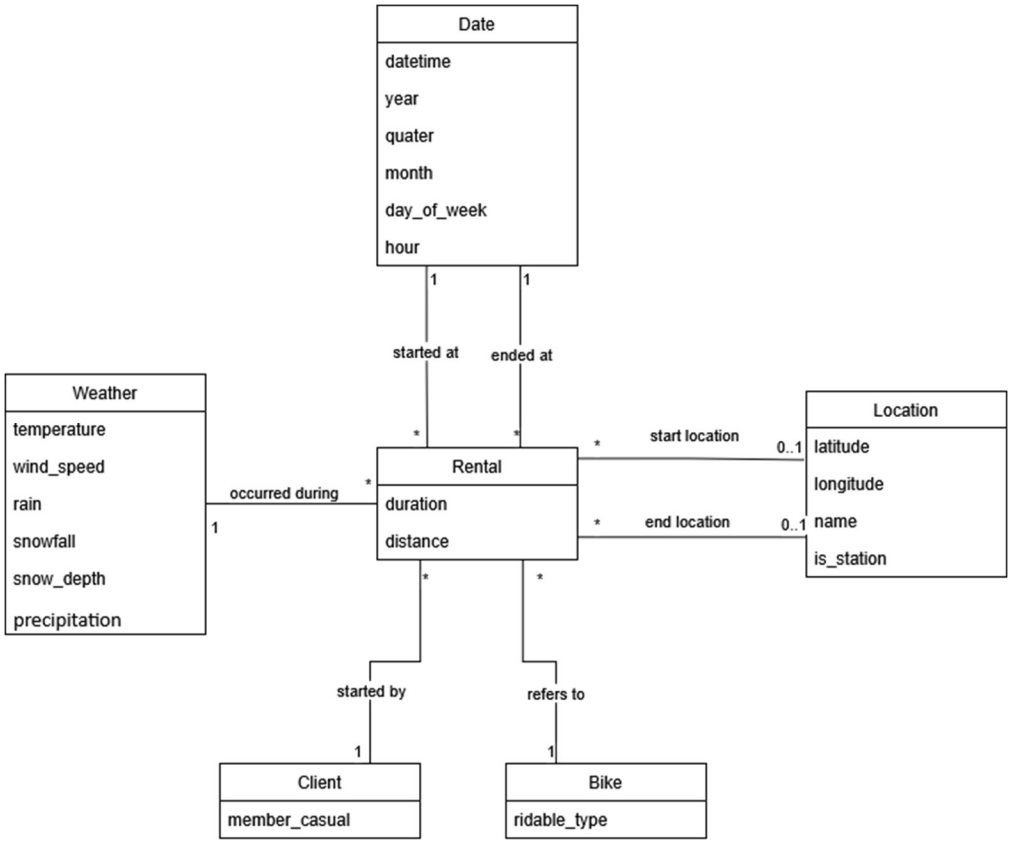

Rysunek 1. Wielowymiarowy model analityczny na poziomie konceptualnym

Wnioski z realizacji zadań

- Uzasadnienie wyboru tematu

Wybrałem ten temat uważam temat mikromobliności za ciekawy i warty uwagi oraz ponieważ w Polsce również trwa rozbudowa infrastruktury rowerowej i coraz więcej osób z niej korzysta. Dla takiej rozbudowy istotne jest aby spełniała potrzeby jej użytkowników i to między innymi one są przedmiotem analizowanych danych.

- Uwagi dotyczące realizacji zadań **`Etap 01`**

Problematyczne okazało się ujednolicenie danych dotyczących lokalizacji jako że rower może zostać oddany na stacje, ale nie jest to gwarantowane i czasami może być on pozostawiony poza nią postanowiłem zawrzeć te informacje w jednym wymiarze. Problematyczne było również zdefiniowanie ograniczeń ponieważ musza one uwzględniać realia geograficzne i meteorologiczne analizowanego regionu.

Uwaga:

- Raport z realizacji projektu bez wniosków końcowych ma negatywny wpływ na ocenę realizacji tego procesu!