

Hurtownie danych – Projekt – Etap 03

PWr. Wydział Informatyki i Telekomunikacji Data: 8.05.2026

Student	-----	Ocena
Indeks	<u>280556</u>	
Imię	<u>Mateusz</u>	
Nazwisko	<u>Tereba</u>	

1. Tytuł projektu (wybranego lub zmienionego w celu realizacji)

Analiza wzorców mobilności miejskiej i obciążenia infrastruktury na podstawie systemu Capital Bikeshare w Waszyngtonie.

- **Uzasadnienie wyboru lub zmiany**

Wybrałem ten temat uważam temat mikromobilności za ciekawy i warty uwagi oraz ponieważ w Polsce również trwa rozbudowa infrastruktury rowerowej i coraz więcej osób z niej korzysta. Dla takiej rozbudowy istotne jest aby spełniała potrzeby jej użytkowników i to między innymi one są przedmiotem analizowanych danych.

2. Charakterystyka dziedziny problemowej

Dziedzina projektu obejmuje transport miejski oraz dynamicznie rozwijający się sektor mikromobilności, ze szczególnym uwzględnieniem systemów publicznego współdzielenia rowerów. Rozwiązania te stanowią kluczowy element infrastruktury komunikacyjnej w nowoczesnych aglomeracjach, odpowiadając na wyzwania związane z redukcją zatorów drogowych oraz zrównoważonym rozwojem.

Istotne dla tej dziedziny są również panujące warunki atmosferyczne, od których w dużym stopniu zależy zmienność w wykorzystaniu systemów rowerów miejskich. Pogoda wpływa nie tylko na samą decyzję o wypożyczeniu, ale także na zachowania użytkowników, takie jak długość przejazdów czy wybór docelowego miejsca zwrotu pojazdu.

Przedmiotem analizy będzie przejazd rowerem, to jest wypożyczenie i zwrócenie go. Zdarzenie to charakteryzuje się godziną i miejscem rozpoczęcia i zakończenia przejazdu, klasyfikacją wypożyczającego, typem wypożyczanego roweru, a także warunkami atmosferycznymi panującymi podczas przejazdu.

2.1 Opis obszaru analizy (wybrany fragment dziedziny, przeznaczony do szczegółowej analizy i opracowania hurtowni danych)

Analizowane dane ograniczają się do przejazdów ze stolicy Stanów Zjednoczonych miasta Waszyngton od maja 2020 do sierpnia 2024. Zbiór ten zawiera dane o każdym zarejestrowanym przejeździe, takie jak czas rozpoczęcia i zakończenia, stacje początkową i końcową, klasyfikację wypożyczającego oraz typ

pojazdu. Zbiór danych został dodatkowo rozszerzony o dane pogodowe z tego samego okresu, aby dodać odpowiedni kontekst do analizy.

2.2 Problemy w rozpatrywanej dziedzinie

- P01 – Nierównomierne obciążenie stacji – w godzinach szczytu niektóre stacje są wykorzystywane o wiele częściej niż inne, co może prowadzić do braku wolnych miejsc lub rowerów.
- P02 – Silna sezonowość – liczba przejazdów dynamicznie zmienia się w przeciągu roku co stanowi problem przy rozmieszczaniu zasobów.
- P03 – Różne zachowania użytkowników – osoby posiadające subskrypcje i sporadyczni użytkownicy posiadają inne wzorce korzystania z usług, co utrudnia przewidywanie zachowań użytkowników.
- P04 – Wpływ warunków atmosferycznych – zmienne warunki pogodowe zaburzają wzorce wypożyczeń i utrudniają przewidywanie zapotrzebowania.
- P05 – Preferencja wypożyczanych rowerów - wpływ dostępnych rodzajów rowerów na zachowania użytkowników.

2.3 Cel przedsięwzięcia

2.3.1 Oczekiwania i potrzeby w zakresie wsparcia podejmowania decyzji

Jakie decyzje mają być wspierane?

- Wybór optymalnych lokalizacji dla nowych stacji w mieście
- Alokacje odpowiedniej ilości rowerów na dane stacje
- Wyznaczanie okresów serwisowania rowerów
- Wybór rodzaju i kupno nowych rowerów
- Rozbudowa obecnie istniejących stacji

2.3.2 Pytania badawcze - - Zakres analizy

1. Q01 –Które ze stacji są najczęściej używane, a które najrzadziej?
2. Q02 – Jakie podróże są najczęściej wykonywane (pomiędzy którymi stacjami)?
3. Q03 – Czy istnieją miejsca, w których należy utworzyć nowe stacje?
4. Q04 – W jaki sposób warunki pogodowe wpływają na liczbę wypożyczeń rowerów?
5. Q05 – Czy subskrybenci wypożyczają rowery częściej od okazjonalnych użytkowników?
6. Q06 – W jakich okresach rowery są używane najmniej?
7. Q07 – Czy istnieje różnica w czasach przejazdów lub w pokonywanych dystansach pomiędzy rodzajami rowerów?

2.3.3 Potencjalni użytkownicy (Interesariusze i użytkownicy)

Kto jest odbiorcą raportów i analiz?

- Zarząd spółki
- Dział ds. Operacji i Logistyki
- Dział Utrzymania Serwisu
- Dział Marketingu
- Władze Miasta
- Urbaniści

3. Dane źródłowe

3.1. Źródła danych

Charakterystyka pliku zawierający danę źródłowe przeznaczone do stworzenia tematycznej hurtowni danych jest przedstawiona w tab. 1.

Tabela 1. Zbiory danych źródłowych

Lp.	Plik	Typ	Liczba rek.	Rozmiar[MB]	Opis
1.	Daily_rent_detail	Csv	16086672	2795	Dane szczegółowo opisujące pojedyncze przejazdy
2.	Station_list	Csv	916	0.03	Zbiór stacji (id stacji, nazwa)
3.	Usage_frequency	Csv	873318	36.6	Dane przedstawiające zagregowane użycie poszczególnych stacji w danych dniach
4.	open-meteo-38.91N77.07W12m	Csv	38016	1.7	Dane przedstawiające warunki pogodowe w danych dniach co godzinę

3.2. Lokalizacja, dostępność danych źródłowych

Użyte do analizy dane zostały pobrane z platformy Kaggle oraz dodatkowo zbiór danych pogodowych ze strony Open-Meteo, który posiada większą dokładność (dane są zbierane co godzinę) niż zbiór z Kaggle (posiada on tylko dane dzienne).

- <https://www.kaggle.com/datasets/taweilo/capital-bikeshare-dataset-202005202408>
- <https://open-meteo.com/en/docs/historical-weather-api>

3.3. Słownik danych – interpretacja

Interpretacja oraz wyjaśnienie znaczeń pojęć dziedzinowych zostały zawarte w tab.2.

Tabela 2. Słownik atrybutów

Plik: daily_rent_detail.csv				
Lp.	Atrybut	Typ danych	Znaczenie	Ograniczenia dziedzinowe, uwagi
1.	end_lat	float	Szerokość geograficzna punktu końcowego.	Wartości zmiennoprzecinkowe z przedziału od 38.22 do 39.57. Mogą wystąpić wartości NULL, jeśli przejazd nie został poprawnie zakończony. Lokalizacja powinna znajdować się w okolicach Waszyngtonu dlatego ograniczono ją do około 75km od jego centrum.
2.	end_lng	float	Długość geograficzna punktu końcowego.	Wartości zmiennoprzecinkowe z przedziału od -77,90 do -76.17. Mogą wystąpić wartości NULL, jeśli przejazd nie został poprawnie zakończony. Lokalizacja powinna znajdować się w okolicach Waszyngtonu dlatego ograniczono ją do około 75km od jego centrum.
3.	end_station_id	integer	Identyfikator stacji końcowej.	Może być wartością NULL jeśli przejazd zakończył się poza stacją, w przeciwnym wypadku musi istnieć w tabeli station_list.
4.	end_station_name	string	Pełna nazwa stacji końcowej.	Może być wartością NULL jeśli przejazd zakończył się poza stacją, w

				przeciwnym wypadku musi istnieć w tabeli station_list.
5.	ended_at	datetime	Data i dokładny czas zakończenia przejazdu.	Data zapisana w formacie: YYYY-MM-DD HH:MM:SS. Wartość musi być późniejsza niż started_at oraz mieścić się w przedziale od maja 2020 do sierpnia 2024
6.	member_casual	string	Wskazuje typ użytkownika.	Wartość obligatoryjna, przyjmuje tylko dwie wartości dopuszczalne: member (zarejestrowany użytkownik) lub casual (okazjonalny).
7.	ridable_type	string	Rodzaj wypożyczonego roweru.	Wartość obligatoryjna, przyjmuje ograniczone wartości: docked_bike, electric_bike, classic_bike.
8.	ride_id	string	Unikalny identyfikator przejazdu.	16-znakowy ciąg alfanumeryczny. Obligatoryjny, unikalny dla każdego wypożyczenia (w danych źródłowych występują powtórzenia)
9.	start_lat	float	Szerokość geograficzna punktu startowego.	Wartości zmiennoprzecinkowe z przedziału od 38.22 do 39.57. Mogą wystąpić wartości NULL, jeśli przejazd nie został poprawnie zakończony. Lokalizacja powinna znajdować się w okolicach Waszyngtonu dlatego ograniczono ją do około 75km od jego centrum.
10.	start_lng	float	Długość geograficzna punktu startowego.	Wartości zmiennoprzecinkowe z przedziału od -77,90 do -76.17. Mogą wystąpić wartości NULL, jeśli przejazd nie został poprawnie zakończony. Lokalizacja powinna znajdować się w okolicach Waszyngtonu dlatego ograniczono ją do około 75km od jego centrum.
11.	start_station_id	integer	Identyfikator stacji początkowej.	Może być wartością NULL jeśli przejazd rozpoczął się poza stacją, w przeciwnym wypadku musi istnieć w tabeli station_list

12.	start_station_name	string	Pełna nazwa stacji początkowej.	Może być wartością NULL jeśli przejazd rozpoczął się poza stacją, w przeciwnym wypadku musi istnieć w tabeli station_list
13.	started_at	datetime	Data i dokładny czas rozpoczęcia przejazdu.	Data zapisana w formacie: YYYY-MM-DD HH:MM:SS. Wartość musi być wcześniejsza niż ended_at oraz mieścić się w przedziale od maja 2020 do sierpnia 2024

Plik: station_list.csv				
Lp.	Atrybut	Typ danych	Znaczenie	Ograniczenia dziedzinowe, uwagi
1.	station_id	integer	Unikalny identyfikator stacji dokującej.	Wartość obligatoryjna, unikalna, składa się z cyfr (w danych źródłowych występują powtórzenia)
2.	station_name	string	Pełna nazwa lokalizacji stacji.	Wartość obligatoryjna

Plik: usage_frequency.csv				
Lp.	Atrybut	Typ danych	Znaczenie	Ograniczenia dziedzinowe, uwagi
1.	date	date	Data, dla której podsumowano statystyki.	Data zapisana w formacie: YYYY-MM-DD. Wartość obligatoryjna, powinna mieścić się w przedziale od maja 2020 do sierpnia 2024
2.	dropoff_counts	int	Dzienna liczba zwrotów rowerów na danej stacji.	Wartość całkowita, nieujemna (w danych źródłowych zostały zapisane jako liczba zmiennoprzecinkowa)
3.	pickup_counts	int	Dzienna liczba wypożyczeń rowerów z danej stacji.	Wartość całkowita, nieujemna
4.	station_name	string	Pełna nazwa stacji rowerowej.	Wartość obligatoryjna, powinna znajdować się w tabeli station_list

Lp.	Atrybut	Typ danych	Znaczenie	Ograniczenia dziedzinowe, uwagi
-----	---------	------------	-----------	---------------------------------

1.	precipitation	float	Łączna liczba opadów z poprzedniej godziny w milimetrach.	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od 0 do 100. Nazwa atrybutu zmieniona względem oryginału, usunięto niepotrzebne znaki.
2.	rain	float	Ilość deszczu w przeciągu poprzedniej godziny w milimetrach	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od 0 do 100. Nazwa atrybutu zmieniona względem oryginału, usunięto niepotrzebne znaki.
3.	snow_depth	float	Głębokość śniegu podana w metrach	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od 0 do 1.5. Nazwa atrybutu zmieniona względem oryginału, usunięto niepotrzebne znaki.
4.	snowfall	float	Ilość śniegu w przeciągu poprzedniej godziny w centymetrach	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od 0 do 20. Nazwa atrybutu zmieniona względem oryginału, usunięto niepotrzebne znaki.
5.	temperature	float	Temperatura powietrza na wysokości 2m nad ziemią podana w stopniach Celsjusza	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od -20 do 40 stopni Celsjusza. Nazwa atrybutu zmieniona względem oryginału, usunięto niepotrzebne znaki.
6.	wind_speed	float	Średnia prędkość wiatru podana w km/h.	Wartość obligatoryjna, liczba zmiennoprzecinkowa, wartości od 0 do 200. Nazwa atrybutu zmieniona względem oryginału, usunięto niepotrzebne znaki.
7.	time	datetime	Data i czas pomiaru.	Data zapisana w formacie: YYYY-MM-DD HH:MM:SS. Wartość obligatoryjna, unikalna. Musi mieścić się w przedziale od maja 2020 do sierpnia 2024

3.4. Ocena jakościowa danych

Wynik analizy jakościowej przeprowadzonej za pomocą programu Tableau oraz profilu danych SSIS został przedstawiony w tab. 3.

Tabela 3. Ocena jakościowa danych

Plik: daily_rent_detail.csv				
Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych
1.	end_lat	float	Wartości od 0 do 43,07	Występują wartości NULL (0.16%), wartości wychodzą poza dopuszczalny przedział.
2.	end_lng	float	Wartości od -78,1 do 0	Występują wartości NULL (0.16%), wartości wychodzą poza dopuszczalny przedział.
3.	end_station_id	integer	Wartości od 30200 do 33200, anomalia w postaci 2 wartości alfanumerycznych	Dwa wystąpienia wartości alfanumerycznej, reszta składa się z liczb zmiennoprzecinkowych (~89,9%) lub całkowitych (~0,4%) występują wartości NULL (~9,7%). Wartości alfanumeryczne nie występują w danych z pliku station_list.
4.	end_station_name	string	Długość od 10 do 61 znaków	Występują wartości NULL (9.7%)
5.	ended_at	datetime	Wartości od 01.01.2000 15:55:56 do 31.08.2024 23:59:55	Brak wartości NULL, daty poza dopuszczalnym zakresem
6.	member_casual	string	Wszystkie rekordy mają dokładnie 6 znaków	Brak wartości NULL, wszystkie wartości zgodne z ograniczeniami.
7.	ridable_type	string	Długość od 11 do 13 znaków	Brak wartości NULL, wszystkie wartości są poprawne.
8.	ride_id	string	Dokładnie 16 znaków	Brak wartości NULL, występują powtórzenia stanowią one 0.0009% zbioru.
9.	start_lat	float	Wartości od 38,37 do 39,14	Występują wartości NULL (10 rekordów), wartości mieszczą się w dopuszczalnym przedziale

10.	start_lng	float	Wartości od -77,4 do -76,78	Występują wartości NULL (10 rekordów), wartości mieszczą się w dopuszczalnym przedziale
11.	start_station_id	integer	Wartości od 30200 do 33200, anomalia w postaci 2 wartości alfanumerycznych	Dwa wystąpienia wartości alfanumerycznej, reszta składa się z liczb zmiennoprzecinkowych (~89,6%) lub całkowitych (~1,3%) występują wartości NULL (~9%). Wartości alfanumeryczne nie występują w danych z pliku station_list.
12.	start_station_name	string	Długość od 10 do 61 znaków	Występują wartości NULL (9%)
13.	started_at	datetime	Wartości od 01.05.2020 00:02:02 do 31.08.2024 23:57:12	Brak wartości NULL, wartości mieszczą się w dopuszczalnym przedziale

Plik: station_list.csv				
Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych
1.	station_id	integer	Wartości od 30200 do 33200	Brak wartości NULL, natomiast występują powtórzenia wartości (procent unikalnych wartości wynosi 88.2%)
2.	station_name	string	Długości od 10 do 61 znaków	Brak wartości NULL, występuje 7 powtórzonych wartości (99.2% wartości jest unikalnych)

Plik: usage_frequency.csv				
Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych
1.	date	date	Wartości od 01.05.2020 do 31.08.2024	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym zakresie.
2.	dropoff_counts	int	Wartości od 0 do 460	Brak wartości NULL, liczby całkowite zapisane jako zmiennoprzecinkowe

3.	pickup_counts	int	Wartości od 1 do 444	Brak wartości NULL, wszystkie całkowitoliczbowe
4.	station_name	string	Wartości od 10 do 61	Brak wartości NULL

Plik: open-meteo-38.91N77.07W12m.csv				
Lp.	Atrybut	Typ danych	Zakres wartości	Uwagi - ocena jakości danych
1.	precipitation	float	Zakres wartości od 0 do 29	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.
2.	rain	float	Zakres wartości od 0 do 29	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.
3.	snow_depth	float	Zakres wartości od 0 do 0,16	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.
4.	snowfall	float	Zakres wartości od 0 do 3,15	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.
5.	temperature	float	Zakres wartości od -14,2 do 38,2	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.
6.	time	datetime	Zakres wartości od 01.05.2020 00:00:00 do 31.08.2024 23:00:00	Brak wartości NULL, wszystkie wartości unikalne, wartości mieszczą się w dozwolonym przedziale, format daty należy zmienić aby możliwe było wczytanie danych.
7.	wind_speed	float	Zakres wartości od 0 do 32,8	Brak wartości NULL, wszystkie wartości mieszczą się w dozwolonym przedziale.

Uwaga:

Ocena jakości atrybutu i jego wartości powinna umożliwić podjęcie decyzji, czy wymaga oczyszczenia zbioru wartości lub można pominąć ten atrybut w kontekście rozważanego zakresu analiz biznesowych.

4. Analityczne modele wielowymiarowe

4.1. Fakty **podlegające analizie oraz ich miary**

Analizie będzie podlegał zbiór zarejestrowanych zdarzeń (tab. 4.)

Tabela 4. Fakty podlegające analizie

Lp.	Fakty	Miary	Uwagi
1.	Rental	Duration, distance	Na podstawie tabeli wypożyczeń obliczono czas przejazdu i przebyty dystans (w linii prostej)

4.2. Kontekst analizy faktów

Ustalony kontekst analizy faktów został przedstawiony w tab. 5.

Tabela 5. Wymiary analizy faktów


Lp.	Wymiar	Atrybuty	Uwagi
1.	Date	full_date, year, month, day_of_week, day_type, season	Z danych z tabeli wypożyczeń wyodrębniono daty, pożyczania i zwrotu roweru. W celu ułatwienia analizy dodano atrybuty: pełną datę, miesiąc, dzień tygodnia, typ dnia (np. dzień roboczy, weekend) oraz, porę roku.
2.	Time	hour, minute, part_of_day	Wymiar przedstawia godziny i minuty wraz z typem pory dnia (np. poranne godziny szczytu, noc)
3.	Location	latitude, longitude, station_name, location_type	Zagregowane dane z tabel wypożyczeń i stacji opisują miejsce oddania roweru, rodzaj lokalizacji (np. stacja, poza stacją) i jeśli tak nazwę stacji.
4.	Weather	Temperature_range, wind_speed_range, rain_range, snowfall_range, snow_depth_range	Z tabeli danych pogodowych wybrano wszystkie dane istotne dla analizy takie jak temperatura, wiatr, opady i głębokość śniegu. Dane te zostaną zagregowane do przedziałów.
5.	Client	member_casual	W kontekście klienta jedyną daną którą posiadamy jest status jego subskrypcji.

6.	Bike	ridable_type	W kontekście wypożyczanego roweru znamy tylko jego typ.
----	------	--------------	---

5. Modele wielowymiarowe (UML)

Po przeanalizowaniu atrybutów źródła danych oraz ustalonego faktu/faktów i kontekstu analizy zaproponowano wielowymiarowy model konceptualny (rys. 1.). Składa się on z faktów Rental (wypożyczenie) oraz wymiarów: Date, Time, Location, Weather, Client i Bike. Model ten reprezentowany jest w postaci schematu na rys. 1. .

Uwaga: własności klas **nie zawierają kluczy obcych** (jest to mechanizm implementacyjny!)



Rysunek 1. Wielowymiarowy model analityczny na poziomie konceptualnym

6. Implementacja modeli wielowymiarowych (6.4 – opcjonalnie)

6.1. Schemat bazy danych HD (skrypt SQL z zachowaniem kolorowania)

```
DROP TABLE IF EXISTS Fact_Rental;
DROP TABLE IF EXISTS Dim_Rental_Profile;
DROP TABLE IF EXISTS Dim_Date;
DROP TABLE IF EXISTS Dim_Location;
DROP TABLE IF EXISTS Dim_Time;
DROP TABLE IF EXISTS Dim_Weather;

CREATE TABLE Dim_Date (
    date_id INT NOT NULL,
    full_date DATE NOT NULL,
    [year] INT NOT NULL,
    [month] INT NOT NULL,
    day_of_week NVARCHAR(20) NOT NULL,
    day_type NVARCHAR(20) NOT NULL,
    season NVARCHAR(20) NOT NULL,

    CONSTRAINT PK_Dim_Date PRIMARY KEY (date_id)
);

CREATE TABLE Dim_Time (
    time_id INT NOT NULL,
    [hour] INT NOT NULL,
    [minute] INT NOT NULL,
    part_of_day NVARCHAR(20) NOT NULL,

    CONSTRAINT PK_Dim_Time PRIMARY KEY (time_id)
);

CREATE TABLE Dim_Location (
    location_id INT IDENTITY(1,1) NOT NULL,
    latitude DECIMAL(8, 5) NULL,
    longitude DECIMAL(8, 5) NULL,
    station_id INT NULL,
    station_name NVARCHAR(100) NULL,
    location_type NVARCHAR(20) NOT NULL,

    CONSTRAINT PK_Dim_Location PRIMARY KEY (location_id)
);

CREATE TABLE Dim_Weather (
    weather_id INT NOT NULL,
    temperature_range NVARCHAR(10) NOT NULL,
    wind_speed_range NVARCHAR(10) NOT NULL,
    rain_range NVARCHAR(10) NOT NULL,
    snowfall_range NVARCHAR(10) NOT NULL,
    snow_depth_range NVARCHAR(10) NOT NULL,

    CONSTRAINT PK_Dim_Weather PRIMARY KEY (weather_id)
);

CREATE TABLE Dim_Rental_Profile (
    profile_id INT IDENTITY(1,1) NOT NULL,
```

```

member_casual VARCHAR(20) NOT NULL,
ridable_type VARCHAR(20) NOT NULL,

CONSTRAINT PK_Dim_Rental_Profile PRIMARY KEY (profile_id)
);

CREATE TABLE Fact_Rental (
    rental_id INT IDENTITY(1,1) NOT NULL,
    ride_id CHAR(16),

    start_date_id INT NOT NULL,
    end_date_id INT NOT NULL,

    start_time_id INT NOT NULL,
    end_time_id INT NOT NULL,

    start_location_id INT NOT NULL,
    end_location_id INT NOT NULL,

    weather_id INT NOT NULL,
    profile_id INT NOT NULL,

    duration INT NOT NULL,
    distance FLOAT NOT NULL,

    CONSTRAINT PK_Fact_Rental PRIMARY KEY (rental_id),
    CONSTRAINT UQ_Fact_Rental_RideID UNIQUE (ride_id),

    CONSTRAINT FK_Fact_StartDate FOREIGN KEY (start_date_id) REFERENCES
Dim_Date(date_id),
    CONSTRAINT FK_Fact_EndDate FOREIGN KEY (end_date_id) REFERENCES
Dim_Date(date_id),

    CONSTRAINT FK_Fact_StartTime FOREIGN KEY (start_time_id) REFERENCES
Dim_Time(time_id),
    CONSTRAINT FK_Fact_EndTime FOREIGN KEY (end_time_id) REFERENCES
Dim_Time(time_id),


    CONSTRAINT FK_Fact_StartLoc FOREIGN KEY (start_location_id) REFERENCES
Dim_Location(location_id),
    CONSTRAINT FK_Fact_EndLoc FOREIGN KEY (end_location_id) REFERENCES
Dim_Location(location_id),

    CONSTRAINT FK_Fact_Weather FOREIGN KEY (weather_id) REFERENCES
Dim_Weather(weather_id),
    CONSTRAINT FK_Fact_Rental_Profile FOREIGN KEY (profile_id) REFERENCES
Dim_Rental_Profile(profile_id),
);

```

6.2. Widok danych (Data Source View – kopia ekranu)

Rysunek 2. przedstawia widok danych, względem modelu koncepcyjnego (Rysunek 1.) połączono wymiary roweru i klienta w jeden wymiar profil wypożyczenia. Decyzja ta wynikała z tego że wymiary te mają mało unikalnych wartości.



Rysunek 2. Widok danych wszystkich tabel zaimplementowanych w hurtowni danych

6.3. Wymiary (kopia ekranu: Atrybuty + Hierarchie)

1. Date

Wymiar daty składający się z atrybutów: daty, roku, pory roku, miesiąca, dnia tygodnia i rodzaju dnia został przedstawiony na Rysunku 3., zawiera on wszystkie atrybuty przedstawione w Tabeli


5.. Rysunek 3. przedstawia również hierarchię rok-pora roku – miesiąc – dzień.



Rysunek 3. Wymiar daty oraz hierarchia

2. Time

Wymiar czasu składa się z atrybutów: godziny i pory dnia, został przedstawiony na Rysunku 4., zawiera wszystkie atrybuty, które zostały przedstawione w Tabeli 5.. Na Rysunku 4. znajduje się również hierarchia pora dnia – godzina – minuta.



Rysunek 4. Wymiar czasu oraz hierarchia

3. Location

Wymiar lokalizacji został przedstawiony na Rysunku 5. i składa się on z atrybutów: długości i szerokości geograficznej, typu lokalizacji i nazwy stacji. Widoczna jest również hierarchia typ lokalizacji – nazwa stacji.



Rysunek 5. Wymiar lokalizacji oraz hierarchia

4. Weather

Wymiar pogody został przedstawiony na Rysunku 6. i składa się z atrybutów: przedział ilości deszczu, przedział głębokości śniegu, przedział opadów śniegu, przedział temperatury, przedział prędkości wiatru. Wymiar posiada wszystkie atrybuty zdefiniowane dla niego w Tabeli 5. i nie

została utworzona dla niego hierarchia.

Attributes	Hierarchies
 Dim Weather - Rain Range - Snow Depth Range - Snowfall Range - Temperature Range  Weather Id - Wind Speed Range	To create a new hierarchy, drag an attribute here.

Rysunek 6. Wymiar pogody

5. Rental_Profile


Wymiar profilu wypożyczenia został przedstawiony na *Rysunku 7.*, składa się on z kategorii użytkownika wypożyczającego rower oraz rodzaju wypożyczanego roweru. Wymiar jest połączeniem przedstawionych w *Tabeli 5.* wymiarów klienta i roweru, jako że mają one odpowiednio 2 i 3 unikalne wartości. Dla tego wymiaru nie utworzono hierarchii.

Attributes	Hierarchies
 Dim Rental Profile - Member Casual  Profile Id - Ridable Type	To create a new hierarchy, drag an attribute here.

Rysunek 7. Wymiar profilu wypożyczenia

6.4. Modele wielowymiarowe – Kostki (kopia ekranu: Miary + Wymiary + Diagram)

Diagram kostki wraz z miarami i wymiarami został zaprezentowany na *Rysunku 8.* Kostka została stworzona na podstawie faktu zdefiniowanego w *Tabeli 4.* oraz wymiarów opisanych w punkcie 6.3.



Rysunek 8. Diagram kostki dla hurtowni danych wraz z miarami i wymiarami

7. Projekt procesu ETL


7.1. Specyfikacja procesów ETL (Control Flow + Data Flow)

Proces ETL został wykonany w SSIS składa się on z następujących kroków:

1. Opróżnienie tabel poczekalni oraz tabel do przechowywania oczyszczonych danych.
2. Załadowanie danych z plików CSV do poczekalni, z danych pogodowych został odrzucony atrybut precipitation, jako że został on uznany za niepotrzebny. Po załadowaniu danych z pliku jest on przenoszony do archiwum.
3. Konwersja danych takich jak data w danych pogodowych lub zmiana id z liczby zmiennoprzecinkowej na całkowitą w danych wypożyczeń została przeprowadzona już na etapie ładowania danych do poczekalni.

4. Wyczyszczenie danych stacji i usunięcie duplikatów.
5. Sprawdzenie poprawności danych pogodowych.
6. Wyczyszczenie danych wypożyczeń: przypisanie poprawnych id stacji, sprawdzenie poprawności typu roweru i statusu klienta, odrzucenie rekordów z niepoprawnymi współrzędnymi geograficznymi lub datą, uzupełnienie id stacji.
7. Załadowanie danych do hurtowni, kolejno, generuje daty, generuje godziny, ładuje profile klienta, ładuje dane pogodowe, ładuje przetworzone dane lokalizacji i na koniec dane wypożyczeń.

Opisany proces został przedstawiony na Rysunku 9. w kolejnych rzędach znajdują się procesy ładowania danych do poczekalni z plików CSV, czyszczenia danych i generowania oraz ładowania danych do hurtowni.




Rysunek 9. Control Flow wczytywania danych do hurtowni

Poniżej znajduje się opis kroków wykonanych w *control flow*. Omówienie niektórych procesów zostało skrócone ze względu na ich niską złożoność.

1. Opróżnienie poczekalni
Skrypt SQL, który usuwa dane z poczekalni i tabel które przechowują wyczyszczone dane.
2. Wczytywanie Plików Stacji
W pętli for wczytywane są dane stacji, a następnie pliki źródłowe są przenoszone do archiwum.
3. Wczytywanie Plików Pogody
Pętla for wczytująca do poczekalni dane pogodowe. Szczegóły procesu wczytania danych pogodowych zostały przedstawione na Rysunku 10. Podczas wczytywania tych danych dokonywana jest konwersja daty z ciągu znaków do wartości datetime. Data flow ładowanie


pogody składa się z: wczytania pliku pogody, przekształcenia formatu daty, konwersji typu daty i wczytania do poczekalni.



Rysunek 10. Data flow wczytywania danych pogody do poczekalni

4. Wczytywanie Plików Wypożyczeń


Pętla wczytująca do poczekalni pliki z wypożyczeniami. Podczas wczytywania następuje konwersja id stacji z ciągu znaków do typu integer, jeśli konwersja nie powiedzie się błędne rekordy są zapisywane w odpowiednim pliku. Proces wczytywania danych wypożyczeń do poczekalni został przedstawiony na Rysunku 11.



Rysunek 11. Data flow wczytywania danych wypożyczeń do poczekalni

5. Czyszczenie Stacji

Data flow czyszczenia stacji został przedstawiony na Rysunku 12. składają się na niego następujące kroki. Z poczekalni stacji pobierane są dane, w których następnie rozdzielam stacje z unikalnym id, od tych których id się powtarza. Dla stacji z powtórzonym id nazwa jest wybierana na podstawie najnowszego rekordu z tabeli wypożyczeń (jako że on również przechowuje nazwy stacji). Następnie wykonuje przeszukiwanie rozmyte aby usunąć stacje z podobnymi nazwami. Próg podobieństwa musi być ustawiony wysoko (0,95) ponieważ nazwy stacji w znacznej części odpowiadają nazwą ulic przy których się znajdują, a te potrafią się różnić pojedynczą litera lub cyfrą (np. „10th & H St NE” i „11th & H St NE”) ale być zupełnie innymi ulicami. Reprezentanci są zapisywani do tabeli czystych stacji, a duplikaty do tabeli duplikatów stacji.




Rysunek 12. Data flow czyszczenia danych stacji

6. Czyszczenie Pogody

Czyszczenie danych pogodowych polega jedynie na sprawdzeniu czy wartości mieszczą się w


odpowiednich przedziałach. Dane które wychodzą poza przedział są odrzucane i zapisywane do odpowiedniego pliku. Proces ten został przedstawiony na Rysunku 13.



Rysunek 13. Data flow czyszczenia pogody

7. Czyszczenie Wypożyczeń

Z poczekalni za pomocą zapytania SQL (Kod 1.) wybierane są wybierane wypożyczenia z unikalnymi identyfikatorami przejazdu, jeśli identyfikatory się powtarzają zostaje wybrane najnowsze. Następnie sprawdzana jest poprawność atrybutów wypożyczenia i czy mieszczą się one w odpowiednich przedziałach, rekordy z niepoprawnymi wartościami zostają odrzucone i zapisane w odpowiednim pliku. Ponieważ istnieją rekordy wypożyczeń, w których jest zawarta nazwa stacji końcowej natomiast brakuje id, dokonywane jest sprawdzenie czy nazwa stacji nie występuje w danych stacji i na tej podstawie przypisywane jest id, w przypadku niepowodzenia rekord jest zapisywany do pliku. Następnie sprawdzam czy stacje początkowa lub końcowa zostały zakwalifikowane jako duplikaty, jeśli tak to zmieniam id odpowiedniej stacji na id reprezentanta. Na koniec zapisuje wyczyszczone dane do tabeli. Opisany proces został przedstawiony na Rysunku 14.



Rysunek 14. Data flow czyszczenia wypożyczeń

```
WITH DedupedData AS (
    SELECT
        *,
        ROW_NUMBER() OVER(
            PARTITION BY ride_id
            ORDER BY started_at DESC
        ) as rn
    FROM [dbo].[Wypożyczenia Poczekalnia]
)
SELECT *
FROM DedupedData
WHERE rn = 1;
```

Kod 1. Kod SQL wybierający wypożyczenia bez duplikatów

8. Generowanie Dat

Daty są generowane przez skrypt SQL (Kod 1.) jeśli dana data występuje w hurtowni jest pomijana. Skrypt generuje daty z przedziału od 1 maja 2020 do 31 sierpnia 2024 czasu odpowiadający przedziałowi danych wypożyczeń.

```
SET DATEFIRST 1;

DECLARE @StartDate DATE = '2020-05-01';
DECLARE @EndDate DATE = '2024-08-31';

WITH DateCTE AS (
    SELECT @StartDate AS DateValue
    UNION ALL
    SELECT DATEADD(day, 1, DateValue)
    FROM DateCTE
    WHERE DateValue < @EndDate
)
INSERT INTO Dim_Date (date_id, full_date, [year], [month], day_of_week, day_type, season)
SELECT
    YEAR(DateValue) * 10000 + Month(DateValue) * 100 + DAY(DateValue) AS date_id,
    DateValue AS full_date,
    YEAR(DateValue) AS [year],
    MONTH(DateValue) AS [month],
    DATENAME(WEEKDAY, DateValue) AS day_of_week,
    CASE
        WHEN DATEPART(WEEKDAY, DateValue) IN (6, 7) THEN 'Weekend'
```

```

        ELSE 'Weekday'
    END AS day_type,
    CASE
        WHEN MONTH(DateValue) IN (12, 1, 2) THEN 'Winter'
        WHEN MONTH(DateValue) IN (3, 4, 5) THEN 'Spring'
        WHEN MONTH(DateValue) IN (6, 7, 8) THEN 'Summer'
        WHEN MONTH(DateValue) IN (9, 10, 11) THEN 'Autumn'
    END AS season
FROM DateCTE
WHERE NOT EXISTS (
    SELECT 1
    FROM Dim_Date d
    WHERE d.date_id = (YEAR(DateValue) * 10000 + MONTH(DateValue) * 100 + DAY(DateValue))
)
OPTION (MAXRECURSION 0);

```

Kod 2. Skrypt SQL do generujący wartości wymiaru daty

9. Generowanie Godzin

Godziny są generowane za pomocą skryptu SQL (Kod 2.) jeśli dana godzina występuje w hurtowni jest pomijana.

```

WITH MinuteSequence AS (
    SELECT 0 AS MinuteOffset
    UNION ALL
    SELECT MinuteOffset + 1
    FROM MinuteSequence
    WHERE MinuteOffset < 1439
),
CalculatedTime AS (
    SELECT DATEADD(MINUTE, MinuteOffset, CAST('00:00' AS TIME)) AS ActualTime
    FROM MinuteSequence
)
INSERT INTO Dim_Time (time_id, [hour], [minute], part_of_day)
SELECT
    (DATEPART(HOUR, ActualTime) * 100) + DATEPART(MINUTE, ActualTime),
    DATEPART(HOUR, ActualTime),
    DATEPART(MINUTE, ActualTime),
    CASE
        WHEN DATEPART(HOUR, ActualTime) < 5 THEN 'Night'
        WHEN DATEPART(HOUR, ActualTime) < 9 THEN 'Morning Rush'
        WHEN DATEPART(HOUR, ActualTime) < 15 THEN 'Midday'
        WHEN DATEPART(HOUR, ActualTime) < 18 THEN 'Afternoon Rush'
        WHEN DATEPART(HOUR, ActualTime) < 21 THEN 'Evening'
        ELSE 'Night'
    END
FROM CalculatedTime
WHERE NOT EXISTS (
    SELECT 1
    FROM Dim_Time t
    WHERE t.time_id = (DATEPART(HOUR, ActualTime) * 100) + DATEPART(MINUTE, ActualTime)
)
OPTION (MAXRECURSION 1440);


```

Kod 3. Skrypt SQL generujący wartości wymiaru czasu

10. Ładowanie Profilów Wypożyczeń

Z danych wypożyczeń wybierane są unikalne wartości za pomocą zapytania SQL następnie profile

których nie ma w hurtowni są do niej wczytywane. Proces ten został przedstawiony na Rysunku 15.




Rysunek 15. Control flow ładowania profili wypożyczeń

11. Ładowanie Pogody

Wyczyszczone dane pogodowe są przetwarzane każdy atrybut jest klasyfikowany do odpowiedniego przedziału. Przedziały zostały zaprezentowane na Rysunku 16. Na podstawie czasu wykonania pomiaru tworzony jest klucz sztuczny. Rekordy pogody, których nie ma jeszcze w hurtowni są do niej wczytywane. Opisany proces został przedstawiony na Rysunku 17.

Derived Column Name	Derived Column	Expression	Data Type	Length
temperature_range	<add as new column>	ISNULL(temperature) ? "Unknown" : (temperature < -10 ? "< -10" : temperature < 0 ? "-10-0" : temperature < 10 ? "0-10" : temperature < 20 ? "10-20" : temperature < 30 ? "20-30" : temperature < 40 ? "30-40" : "> 40")	Unicode string [DT_WS...	7
wind_speed_range	<add as new column>	ISNULL(wind_speed) ? "Unknown" : (wind_speed < 10 ? "0-10" : wind_speed < 20 ? "10-20" : wind_speed < 30 ? "20-30" : wind_speed < 40 ? "30-40" : "> 40")	Unicode string [DT_WS...	7
rain_range	<add as new column>	ISNULL(rain) ? "Unknown" : (rain <= 0 ? "0" : rain <= 2 ? "0-2" : rain <= 4 ? "2-4" : rain <= 6 ? "4-6" : rain <= 8 ? "6-8" : rain <= 10 ? "8-10" : "> 10")	Unicode string [DT_WS...	7
snowfall_range	<add as new column>	ISNULL(snowfall) ? "Unknown" : (snowfall <= 0 ? "0" : snowfall <= 2 ? "0-2" : snowfall <= 5 ? "2-5" : snowfall <= 10 ? "5-10" : snowfall <= 20 ? "10-20" : "> 20")	Unicode string [DT_WS...	7
snow_depth_range	<add as new column>	ISNULL(snow_depth) ? "Unknown" : (snow_depth <= 0 ? "0" : snow_depth <= 0.02 ? "0-0.02" : snow_depth <= 0.05 ? "0.02-0.05" : snow_depth <= 0.10 ? "0.05-0.10" : "> 0.20")	Unicode string [DT_WS...	9


Rysunek 16. Przedziały wartości opisujących warunki pogodowe



Rysunek 17. Data flow ładowania pogody do hurtowni

12. Ładowanie Lokalizacji


Ładowanie lokalizacji do hurtowni danych zostało przedstawione na Rysunku 18. Na podstawie danych wypożyczeń, dla każdej lokalizacji początkowej i końcowej następuje podział między lokalizacje na stacji oraz poza stacją. Lokalizacje które posiadają id stacji są grupowane i wartości współrzędne geograficzne lokalizacji są uśredniane (pozwala to zgrupować lokalizacje odpowiadające jednej stacji i zachować jej przybliżoną lokalizację). Z lokalizacji, które znajdują się poza stacją usuwane są duplikaty na podstawie współrzędnych geograficznych. Lokalizacje poza i na stacji są odpowiednio oznaczane następnie do hurtowni ładowane są tylko nowe unikalne rekordy.



Rysunek 18. Data flow ładowania lokalizacji do hurtowni

13. Ładowanie Wypożyczeń

Proces ładowania wypożyczeń do hurtowni został przedstawiony na Rysunku 19. Za pomocą zapytania SQL wybierane są dane wypożyczeń wraz z czasem przejazdu w minutach oraz przebytą w linii prostej odległością podaną w metrach obliczoną za pomocą typu geography. Następnie znajdowany jest profil danego przejazdu, wyszukiwana jest lokalizacja początkowa i końcowa (na podstawie id stacji jeśli jest ono dostępne, w przeciwnym wypadku na podstawie współrzędnych geograficznych). Na koniec wypożyczenia które nie znajdują się w hurtowni są do niej zapisywane.



Rysunek 19. Data flow ładowania danych wypożyczeń do hurtowni

Wnioski z realizacji zadań

Uwagi dotyczące realizacji zadań **Etap03**

- Uzasadnienie dokonanych zmian w stosunku do zawartości dokumentu Etap01
 1. Zmiana atrybutów wymiaru pogody na przedziały ma na celu ułatwienie agregacji danych oraz ułatwia ich przetwarzanie i interpretację. Została wykonana, ponieważ niewielkie wahania w warunkach pogodowych nie są istotne dla analizy danych. Nazwy atrybutów również zostały odpowiednio zmienione.
 2. Zmniejszenie dozwolonych przedziałów w ograniczeniach dziedzinowych lokalizacji startowej i końcowej. Poprzednie przedziały były zbyt duże jako że analizujemy wypożyczenia na terenie Waszyngtonu i ewentualnie jego okolic, dlatego obszar został zmniejszony tak aby wynosił około 75km od centrum Waszyngtonu, ponieważ Capital Bikeshare pozwala na wypożyczanie również poza obrębem miasta.
 3. Wyodrębniono dodatkowy wymiar czasu i usunięto atrybuty datetime , quarter i hour z wymiaru daty, natomiast dodano day_type określający czy dzień jest dniem roboczym lub weekendem oraz atrybuty season określający obecną porę roku i

full_date przechowujący samą datę. Wymiar daty był błędnie zaprojektowany i nie pozwalał na optymalne grupowanie danych.

4. Zmieniono atrybut wymiaru lokalizacji is_station na bardziej deskryptywną wartość location_type, aby ułatwić interpretację danych oraz zmieniono nazwę atrybutu name na station_name aby lepiej oddać jej znaczenie. Odpowiednio dostosowano uwagi.
 5. Zmieniono opis modelu wielowymiarowego na zgodny z tym który został przedstawiony w dokumencie
 6. Zmieniono uwagi w słowniku danych dla pliku z danymi pogodowymi aby lepiej uzasadnić zmianę nazwy.
- Ocena realizacji zadań punktu 7.
Projektowanie i implementacja procesu ETL było dość ciężkim zadaniem i wymagało wielu poprawek, ponieważ ciągle natrafiałem na anomalie w danych, które należało wyczyścić. Wiązało się to z wielokrotnym zmienianiem struktury różnych data flow, tak aby jak najlepiej oczyścić dane. Podczas implementacji tego procesu doszedłem również do wniosku że struktura hurtowni nadal wymaga poprawy. Zmienione zostały typy współrzędnych geograficznych z float na stałoprzecinkowe co ułatwia porównania. Do wymiaru lokalizacji został również dodany klucz biznesowy stacji, co pozwala na jej jednoznaczną identyfikację. Z atrybutu weather_id w wymiarze pogody została usunięta automatyczna generacja klucza co pozwala wprowadzić odpowiednio generowany w procesie ETL klucz.

Uwaga:

- **Raport z realizacji projektu bez wniosków końcowych ma negatywny wpływ na ocenę realizacji tego procesu!**

Test poprawkowy: **12.06.2026**

Termin zerowy: **13.06.2026**

Termin przekazania dokumentacji: **9.06.2026 r. do godz. 23:55**

Termin normalny: **19.06.2026**

Termin przekazania dokumentacji: **16.06.2026 r. do godz. 23:55**

Pozostało do zrealizowania do końca kursu – 06.2026

8. Analiza wizualna danych w kontekście pytań badawczych

8.1. Realizacja procesów analitycznych

8.2. Podsumowanie - wnioski z analizy (Pytania badawcze + odpowiedzi)

9. Wnioski końcowe z realizacji projektu

9.1. Problemy związane z realizacją projektu HD

9.2. Pozyskana wiedza i doświadczenie

10. Doświadczenia i rekomendacje dotyczące korzystania z AI na zajęciach z Hurtowni Danych

11. Źródła informacji użyte w etapie analizy danych